

Para un modelo cuadrático y  $n$  puntos tenemos una función de costo

$$X^2(a_0, a_1, a_2) = \sum_{i=1}^n (y_i - (a_0 + a_1 x_i + a_2 x_i^2))^2$$

De la que podemos obtener un sistema de ecuaciones al minimizar  $X^2(a_0, a_1, a_2)$  de la siguiente manera

• Para  $a_0$

$$\frac{\partial X^2}{\partial a_0} = -2 \sum_{i=1}^n (y_i - (a_0 + a_1 x_i + a_2 x_i^2)) = 0$$

podemos despejar  $y_i$  y cancelar el 2 en ambos lados de la igualdad

$$\sum_{i=1}^n a_0 + a_1 x_i + a_2 x_i^2 = \sum_{i=1}^n y_i \quad (1)$$

• Para  $a_1$

$$\frac{\partial X^2}{\partial a_1} = -2 \sum_{i=1}^n (y_i - (a_0 + a_1 x_i + a_2 x_i^2)) x_i = 0$$

$$-2 \sum_{i=1}^n (y_i x_i - (a_0 x_i + a_1 x_i^2 + a_2 x_i^3)) = 0$$

podemos despejar la expresión con  $y_i$  y cancelar el 2 en ambos lados de la igualdad

$$\sum_{i=1}^n a_0 x_i + a_1 x_i^2 + a_2 x_i^3 = \sum_{i=1}^n y_i x_i \quad (2)$$



• Para  $a_2$

$$\frac{\partial X^2}{\partial a_2} = -2 \sum_{i=1}^n (y_i - (a_0 + a_1 x_i + a_2 x_i^2)) x_i^2 = 0$$

$$-2 \sum_{i=1}^n (y_i x_i^2 - (a_0 x_i^2 + a_1 x_i^3 + a_2 x_i^4)) = 0$$

Podemos despejar la expresión con  $y_i$  y cancelar el 2 en ambos lados de la igualdad

$$\sum_{i=1}^n a_0 x_i^2 + a_1 x_i^3 + a_2 x_i^4 = \sum_{i=1}^n y_i x_i^2 \quad (3)$$

Las ecuaciones (1), (2) y (3) conforman nuestro sistema de ecuaciones



Vectorialmente el descenso del gradiente está definido por

$$\vec{\theta}_{j+1} = \vec{\theta}_j - \gamma \left( -2 \sum_{i=1}^N (y_i - M(x_i, \vec{\theta}_j)) \nabla_{\theta} M(x_i, \theta_j) \right)$$

Puesto que el parámetro  $\vec{\theta}$  es un vector con componentes  $\theta_0, \theta_1, \theta_2$  implementadas en el modelo de ajuste

$$M(x, \vec{\theta}) = \frac{\theta_0}{\theta_1 + e^{-\theta_2 x}}$$

al cual le corresponde una función de costo

$$\chi^2(\vec{\theta}) = \sum_{i=1}^N \left( \frac{y_i - M(x_i, \vec{\theta})}{\sigma_i} \right)^2$$

que se deriva para obtener el descenso del gradiente.



Haciendo el error  $\sigma_i = 1$  se puede llegar a la siguiente expresión para el método mencionado

$$\vec{\theta}_{j+1} = \vec{\theta}_j - \gamma \left( -2 \sum_{i=1}^N (y_i - M(x_i, \vec{\theta}_j)) \frac{\partial M(x_i, \vec{\theta}_j)}{\partial \theta_k} \right)$$

donde  $\vec{\theta}_{j+1}$  es el vector  $\vec{\theta} = \begin{pmatrix} \theta_0 \\ \theta_1 \\ \theta_2 \end{pmatrix}$  actualizado,

$\vec{\theta}_j$  es el vector precedente,  $\gamma$  es la tasa de aprendizaje,

$M(x_i, \vec{\theta}_j)$  es el modelo de ajuste evaluado en  $x_i$  y  $\vec{\theta}_j$

y  $\frac{\partial M(x_i, \vec{\theta}_j)}{\partial \theta_k}$  es la derivada parcial del modelo evaluado

con respecto a cada componente de  $\vec{\theta}_j$  ( $k = 0, 1, 2$ ).

Esta última expresión equivale al gradiente

$$\nabla_{\vec{\theta}_j} M(x_i, \vec{\theta}_j) = \left[ \frac{\partial M(x_i, \vec{\theta}_j)}{\partial \theta_0}, \frac{\partial M(x_i, \vec{\theta}_j)}{\partial \theta_1}, \frac{\partial M(x_i, \vec{\theta}_j)}{\partial \theta_2} \right]$$

Que también se expresa de forma compacta en la métrica derivada parcialmente:

$$\frac{\partial \chi^2 \vec{\theta}}{\partial \theta_i} = -2 \sum_{i=1}^N (y_i - M(x_i, \vec{\theta})) \frac{\partial M(x_i, \vec{\theta})}{\partial \theta_i}$$



De esta forma se puede expresar el descenso del gradiente como

$$\begin{bmatrix} \theta_{j+1}^0 \\ \theta_{j+1}^1 \\ \theta_{j+1}^2 \end{bmatrix} = \begin{bmatrix} \theta_j^0 \\ \theta_j^1 \\ \theta_j^2 \end{bmatrix} - \gamma \left( -2 \sum_{i=1}^N (y_i - M(x_i, \vec{\theta}_j)) \begin{bmatrix} \frac{\partial M(x_i, \vec{\theta}_j)}{\partial \theta^0} \\ \frac{\partial M(x_i, \vec{\theta}_j)}{\partial \theta^1} \\ \frac{\partial M(x_i, \vec{\theta}_j)}{\partial \theta^2} \end{bmatrix} \right)$$

lo que equivale a la primera expresión.